基于 YOLOv11+CBAM 的输电线路缺陷检测算法实验报告

数据集 dataset_final_bbox（断股 break / 雷击 thunderbolt / 磨损 wear 3 类）

四套对比：320 SGD / 320 AdamW / 640 SGD / 640 AdamW · 附 896×896 独立对照与数据泄漏核查 · 2026-10-13

一、数据集

本实验面向架空输电线路缺陷检测任务，共检测 3 类缺陷：break（断股）、thunderbolt（雷击）、wear（磨损）。数据标注由 SAM（Segment Anything Model）自动生成分割掩膜，再将 polygon 标注转换为 bbox，形成检测数据集 dataset_final_bbox（task: detect），最后按 8:1:1 划分为训练集 1428 张、验证集 178 张、测试集 179 张（共 1785 张）。各划分的图片数与类别实例数见表 1。

数据划分	图片数	断股 break	雷击 thunderbolt	磨损 wear	实例总数
训练集 train	1428	1014	650	788	2452
验证集 val	178	131	80	64	275
测试集 test	179	150	69	64	283
合计	1785	1295	799	916	3010

表 1　数据集分布（图片数 / 各缺陷类别实例数 / 实例总数）

三类缺陷存在明显的尺度与形态差异：断股（break）为细长线状目标、与背景导线纹理高度相似，标注实例最多（1295 个）；雷击（thunderbolt）为局部熔痕、特征对比度高；磨损（wear）面积较大但边界模糊。这一差异在后续各类别指标中有直接反映。

四套实验均使用同一份数据、同一划分、同一 seed（42）、batch=8、训练 60 epoch，取 fitness 最优的 best.pt，在测试集（179 张图片、283 个标注框）上评估；两两之间只改变输入尺寸或优化器，其余对齐。

关于权重选择的口径：本报告一律报 fitness 最优的 best.pt（fitness = 0.1×mAP50 + 0.9×mAP50-95），不报 last.pt。核对结果：best.pt 与 last.pt 在 test 上的 mAP50 差 ≤0.55pt（wire_v5_640 为 1.2pt），即早停的净收益 ≈ 0；wire_v5_640 单独注明——该 run 的 last 优于 best 1.2pt，若按 last 报则 mAP50 为 0.919。之所以不按 test 结果回头改选 last，是因为「用测试集选权重」本身构成测试集泄漏，比压低 1.2pt 更严重；故全套统一报 best.pt。

早停判据的口径：以 val 早停为准时，best 与 last 的 test mAP50 差 |Δ| ≤0.55pt 视为噪声，不触发对选权重流程的重估；仅当 |Δ| > 1pt 才触发。按此判据，本实验 9 个 run 中只有 wire_v5_640（1.2pt）越过阈值，其余全在噪声内。

注：模型权重按框架默认 fitness（0.1·mAP50 + 0.9·mAP50-95）选择。

二、四套对比总表（测试集）

四套 = 输入尺寸（320 / 640）× 优化器（SGD + lr0=0.01 / AdamW + lr0=0.001）的四种组合。每一套内含 YOLOv11s 基线及其 3 种 CBAM 插入位置、YOLOv12s 基线及 +CBAM、YOLOv5s 基线；其中 640 AdamW 一套只跑了 5 组（v11 四组 + v5），v12 两组本轮未跑，表中如实留空。

表 2~表 5 给出四套各自的完整结果，每套按 test mAP50 降序排列，同一行号只表示同一排名，不代表同一模型；同一模型的跨套对照见表 6。

模型配置	P	R	mAP50	mAP50-95	推理 ms/张	FPS	参数量
v11+CBAM(neck_sppf)	0.8814	0.7157	0.7939	0.3970	3.348	298.7	9,461,819
v11 (baseline)	0.7931	0.7056	0.7787	0.4035	3.482	287.2	9,428,953
v12 (baseline)	0.8768	0.6864	0.7611	0.3798	2.689	371.9	9,254,297
v11+CBAM(both)	0.7932	0.6739	0.7559	0.3871	—	—	9,513,411
v12+CBAM	0.8384	0.6663	0.7435	0.3627	—	—	9,314,179
v11+CBAM(backbone)	0.8561	0.6140	0.7360	0.3548	—	—	9,480,545
v5 (YOLOv5s)†	0.799	0.669	0.721	0.345	10.280	97.3	7,027,720
均值（7 组）	—	—	0.7557	0.3757	—	—	—

表 2　320×320 + SGD　测试集完整结果（best.pt；按 mAP50 降序）

模型配置	P	R	mAP50	mAP50-95	推理 ms/张	FPS	参数量
v11+CBAM(neck_sppf)	0.8270	0.6955	0.7908	0.3964	3.348	298.7	9,461,819
v12+CBAM	0.8653	0.6794	0.7824	0.3920	—	—	9,314,179
v11 (baseline)	0.8152	0.7123	0.7817	0.3940	3.482	287.2	9,428,953
v12 (baseline)	0.8707	0.6924	0.7785	0.3906	2.689	371.9	9,254,297
v11+CBAM(both)	0.8603	0.6651	0.7731	0.3839	—	—	9,513,411
v5 (YOLOv5s)†	0.779	0.729	0.755	0.322	10.280	97.3	7,027,720
v11+CBAM(backbone)	0.7762	0.6407	0.7418	0.3759	—	—	9,480,545
均值（7 组）	—	—	0.7719	0.3793	—	—	—

表 3　320×320 + AdamW　测试集完整结果（best.pt；按 mAP50 降序）

模型配置	P	R	mAP50	mAP50-95	推理 ms/张	FPS	参数量
v5 (YOLOv5s)†	0.917	0.857	0.907	0.500	10.220	97.8	7,027,720
v11+CBAM(backbone)	0.9368	0.8097	0.9061	0.5207	—	—	9,480,545
v11+CBAM(neck_sppf)	0.9080	0.8170	0.9016	0.5192	6.484	154.2	9,461,819
v11 (baseline)	0.8887	0.8264	0.8992	0.5286	6.482	154.3	9,428,953
v11+CBAM(both)	0.8746	0.8284	0.8960	0.5156	—	—	9,513,411
v12+CBAM	0.8855	0.8310	0.8874	0.5071	—	—	9,314,179
v12 (baseline)	0.8648	0.8107	0.8682	0.4909	6.512	153.6	9,254,297
均值（7 组）	—	—	0.8951	0.5117	—	—	—

表 4　640×640 + SGD　测试集完整结果（best.pt；按 mAP50 降序）

模型配置	P	R	mAP50	mAP50-95	推理 ms/张	FPS	参数量
v11+CBAM(both)	0.8872	0.8067	0.8998	0.5072	—	—	9,513,411
v5 (YOLOv5s)†	0.908	0.822	0.891	0.494	10.220	97.8	7,027,720
v11+CBAM(backbone)	0.8973	0.8154	0.8898	0.5073	—	—	9,480,545
v11+CBAM(neck_sppf)	0.9011	0.8047	0.8879	0.5096	6.484	154.2	9,461,819
v11 (baseline)	0.8940	0.8076	0.8873	0.5140	6.482	154.3	9,428,953
均值（5 组）	—	—	0.8912	0.5064	—	—	—

表 5　640×640 + AdamW　测试集完整结果（best.pt；按 mAP50 降序）

表 2~表 5 通用表注：① 推理 ms/张 与 FPS 为端到端口径（读图 + letterbox + 归一化 + 前向 + NMS），RTX 4060 Laptop / FP16 / batch=1 / 同一张测试图，轮转 4 轮丢弃首轮取中位数，测量窗口内 SM 频率均为 2475~2490 MHz（详见 logs/fps_benchmark.txt）。② 推理只与「架构 + 输入尺寸」有关，与优化器无关，故两套 AdamW 沿用同架构同尺寸的实测值。③ 未单测的 CBAM 组记「—」：其推理开销与同架构基线之差低于轮间波动（v11+CBAM(neck)@320 实测 3.348 ms vs 基线 3.482 ms，而基线自身轮间波动 ±0.19 ms）。④ v12 的 640 一套取在 640 下训练的 wire_v12_640；其推理值由同架构产物 wire_v12s_v4@640 测得（参数量逐位一致，9,254,297）。⑤ 参数量为 nc=3 产物口径；v5 用 fuse=False 读法（7,027,720），融合 BN 后为 7,018,216，与 v11 的读法不同口径。⑥ † v5 的推理耗时由 CPU 侧主导（320 与 640 实测几乎相同，10.280 / 10.220 ms），其 FPS 不代表框架的 GPU 算力差距，跨框架比较时须注明。⑦ YOLOv5 官方 val.py 只输出 3 位小数，故 v5 各组保留 3 位。

四套的均值呈阶梯状：320 SGD 0.7557 < 320 AdamW 0.7719 << 640 SGD 0.8951，640 AdamW 0.8912（5 组口径）。640 两套的全部组都落在 0.868~0.907，而 320 两套的最好成绩只有 0.7939 与 0.7908。值得注意的是：640 下按 mAP50，YOLOv5s（0.907）略高于 YOLOv11s（0.8992）；但按 mAP50-95（定位精度），YOLOv11s（0.5286）高于 YOLOv5s（0.500）。综合定位精度、推理速度与架构代际，本报告推荐 YOLOv11s（见第十章综合对比表）。

注（v5-vs-v11 的口径）：640 下 v5 与 v11 的 mAP50 差 0.8pt，小于同一套内 v11 四组的组内极差 1.01pt（0.8960~0.9061），故只作方向性结论、不作量化。另：v5 与 v11 的 lrf 不同（v5 lrf=0.01、cos_lr=false，线性衰减；v11 lrf=0.005、cos_lr=true，余弦衰减），该不对称在 320 / 640 / 896 各套中逐字相同，在本实验范围内不影响分辨率相关结论；但 v5-vs-v11 的量化比较须注明此不对称。

2.5　同一模型在四套下的对照

为排除排名变化带来的干扰，表 6 按模型配置对齐四套结果，并给出 640（取同优化器的 640 一套）相对 320 的绝对提升。

模型配置	320 SGD	320 AdamW	640 SGD	640 AdamW	Δ均值(640−320)
v11 (baseline)	0.7787	0.7817	0.8992	0.8873	+0.1130
v11+CBAM(backbone)	0.7360	0.7418	0.9061	0.8898	+0.1591
v11+CBAM(neck_sppf)	0.7939	0.7908	0.9016	0.8879	+0.1024
v11+CBAM(both)	0.7559	0.7731	0.8960	0.8998	+0.1334
v12 (baseline)	0.7611	0.7785	0.8682	—	+0.0984
v12+CBAM	0.7435	0.7824	0.8874	—	+0.1244
v5 (YOLOv5s)†	0.721	0.755	0.907	0.891	+0.161

表 6　同一模型配置在四套训练设置下的 test mAP50（Δ 为两端可得值的均值之差，640 一侧含同优化器的 AdamW 值；v12 在 640 AdamW 未跑，故其 Δ 只由 SGD 一侧给出；v5 各值只有 3 位小数，其 Δ 末位有 ±0.001 不确定度）

全部 7 个配置在 640 下都取得提升：按表 6 的 Δ 列（两端可得套的均值之差）为 +0.098~+0.161；若两端都只取 SGD 一套，则幅度为 +0.107~+0.186。提升幅度与模型架构无单调关系，说明该收益主要来自输入分辨率对细长小目标的还原，而非某一架构的专属优势。注意 v12 的提升最小（+0.098）且其 640 一侧只有 SGD，该值不宜与其余配置的均值差直接比较。

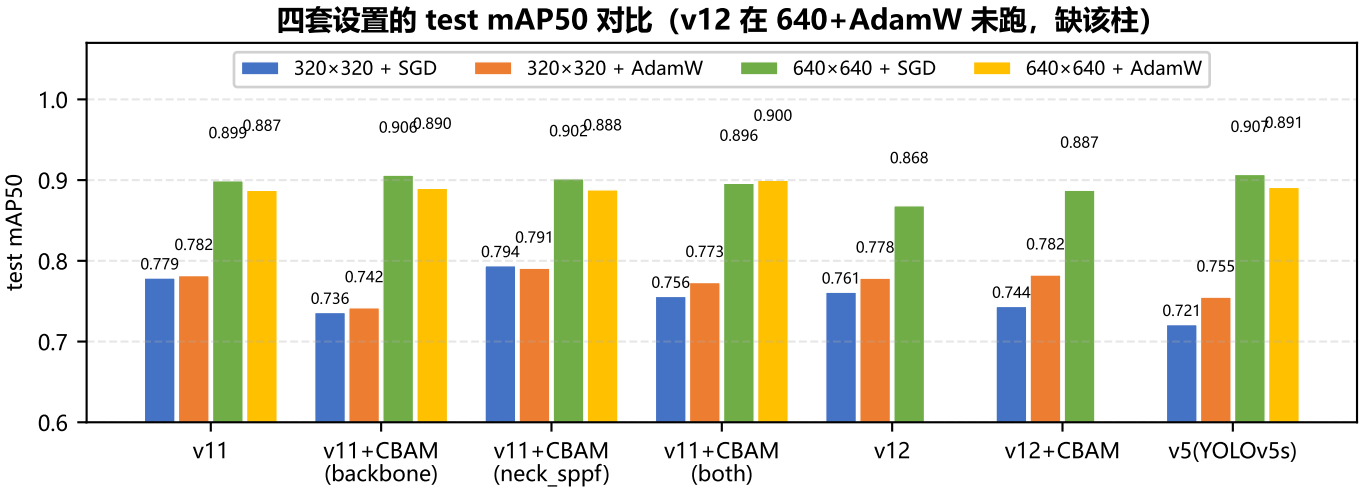


图 1　四套训练设置下各模型配置的 test mAP50 柱状图（横轴为模型配置，四色分别为四套设置；v12 在 640+AdamW 一套未跑；纵轴自 0.60 起，非零起点）

三、优化器对比

在两种分辨率下分别比较 SGD（lr0=0.01，与 YOLOv5 官方配置一致）与 AdamW（lr0=0.001，AdamW 的常用量级）。学习率与优化器必须匹配：早期实验曾让 AdamW 沿用 lr0=0.01，属于错配，同一模型 test mAP50 仅 0.635，换 SGD+lr0=0.01 后升至 0.779（+0.144）；若在错配口径下比较优化器，会得出完全相反的结论。

训练设置	组数	均值 mAP50	均值 mAP50-95	最优组 mAP50
320×320 + SGD	7	0.7557	0.3757	0.7939（v11+CBAM(neck_sppf)）
320×320 + AdamW	7	0.7719	0.3793	0.7908（v11+CBAM(neck_sppf)）
640×640 + SGD	7	0.8951	0.5117	0.9070（v5）
640×640 + AdamW	5	0.8912	0.5064	0.8998（v11+CBAM(both)）

表 7　四套的整体表现。注意 640 AdamW 只有 5 组（缺 v12 两组），其均值与 7 组口径不可直接比较，同构子集对照见表 8。

可比子集	320 SGD	320 AdamW	320 差	640 SGD	640 AdamW	640 差
v11 四组（完全同构）	0.7661	0.7718	+0.0057	0.9007	0.8912	-0.0095
v11 四组 + v5（五组同构）	0.7571	0.7685	+0.0114	0.9020	0.8912	-0.0108

表 8　同构子集下的优化器对照（消除 640 AdamW 缺 v12 造成的口径差）

优化器的优劣随分辨率反转：320 下 AdamW 更高（7 组均值 0.7719 vs 0.7557，+0.0162），而 640 下 AdamW 反而更低。由于 640 AdamW 缺 v12 两组，用完全同构的子集比对更可靠：v11 四组在 320 下 AdamW 高 +0.0057、在 640 下低 −0.0095；五组同构子集同样是 320 下 +0.0114、640 下 −0.0108。两种口径下方向一致地反转，说明 AdamW 的优势并不是稳定的规律，而是依赖分辨率（很可能与不同尺度下的有效学习率、梯度噪声水平有关）。无论哪个方向，优化器带来的差异都不足 0.02，远小于分辨率带来的 +0.14。

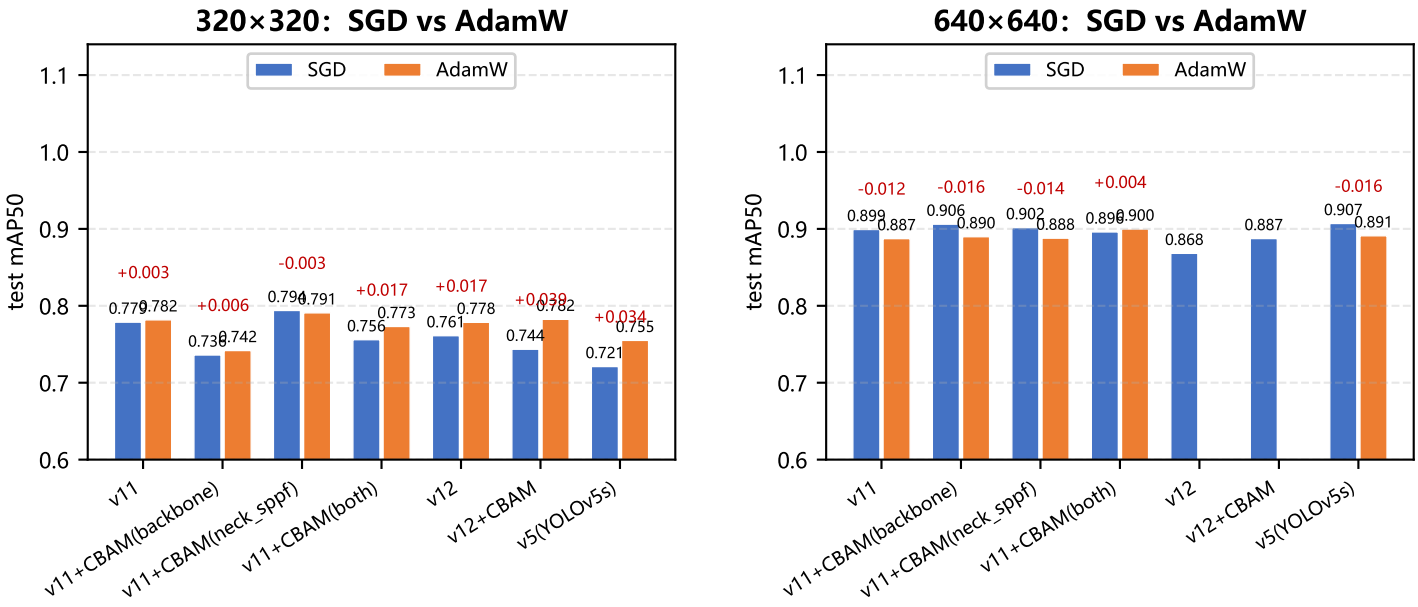


图 2　优化器对比（左 320×320，右 640×640；红色数字为 AdamW − SGD；纵轴自 0.60 起）

图 2 说明：320 下红字多为正（AdamW 领先），640 下红字转为负（SGD 领先），即优化器的相对优劣随分辨率反转；图中 AdamW 缺 v12 与 v12+CBAM 两组（每个面板各少两根柱）。

四、分辨率对比（320 vs 640）

这是本组实验最显著的结论。两两对照（同优化器下 320 → 640）：

优化器	320 均值 mAP50	640 均值 mAP50	Δ mAP50	320 均值 mAP50-95	640 均值 mAP50-95	Δ mAP50-95
SGD	0.7557	0.8951	+0.1393	0.3757	0.5117	+0.1360
AdamW	0.7719	0.8912	+0.1193	0.3793	0.5064	+0.1272

表 9　输入分辨率对整体性能的影响（各套均值；SGD 两侧均 7 组可比，AdamW 一侧 320 为 7 组、640 为 5 组，为避免口径差，AdamW 行的 640 值按 320 同构的 5 组（v11 四组 + v5）计算）

输入尺寸由 320 提升到 640，测试集 mAP50 均值提升约 +0.14，mAP50-95 均值提升约 +0.13，最优组由 0.7939 升至 0.9070。该提升覆盖全部模型配置，无例外。代价是显存峰值由约 0.9 GB 升至约 3.7 GB、单组 60 epoch 训练由约 26 分钟升至约 72 分钟（约 2.8 倍）、推理耗时由 3.48 ms/张升至 6.48 ms/张（约 1.9 倍）。考虑到精度收益（+0.14）比优化器（±0.02）与注意力模块（±0.01）高一个数量级，提高输入分辨率是本任务性价比最高的优化手段。

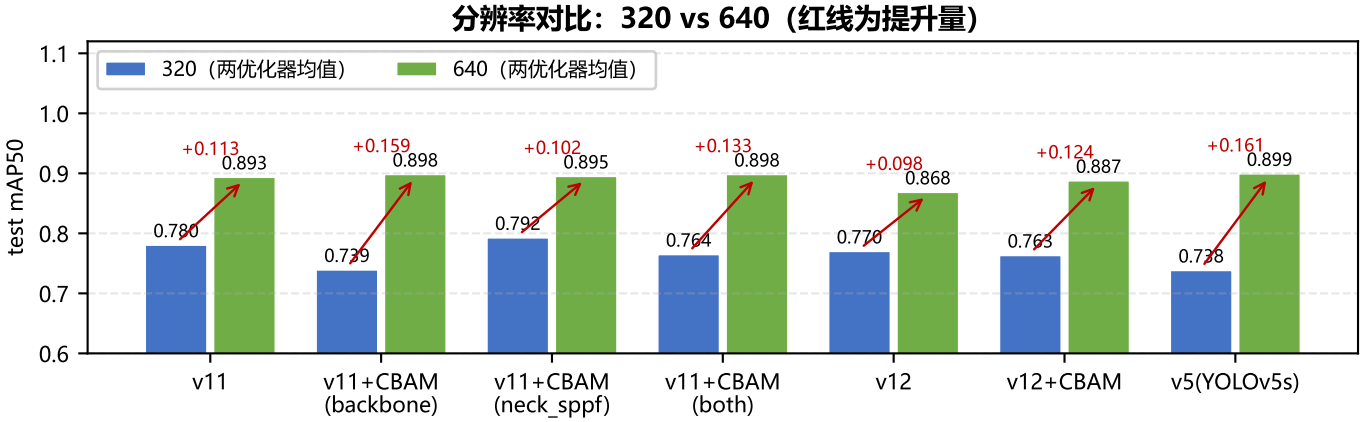


图 3　分辨率对比：320×320 vs 640×640（每个配置取该尺寸下可得套的均值；红色箭头与数字为 640 相对 320 的提升量）

五、CBAM 消融实验

以 YOLOv11s 为基线，分别在骨干网络（backbone 第 2/4/6/8 层）、颈部与 SPPF（neck_sppf 第 9 层）以及两者同时插入 CBAM，在 320/640 × SGD/AdamW 四种设置下各做一组消融。CBAM 的注入采用子类化 DetectionTrainer 并重写 get_model() 的方式，在模型按 yaml 重建完成之后再注入；若在 model.train() 之前对模型对象注入，会被训练器的重建过程丢弃，属于无效注入（曾表现为 +CBAM 与 baseline 参数量完全相同、层数也完全相同）。参数量核验：baseline 9,428,953，backbone +51,592，neck_sppf +32,866，both +84,458，与注入层数成正比且逐位可复现。

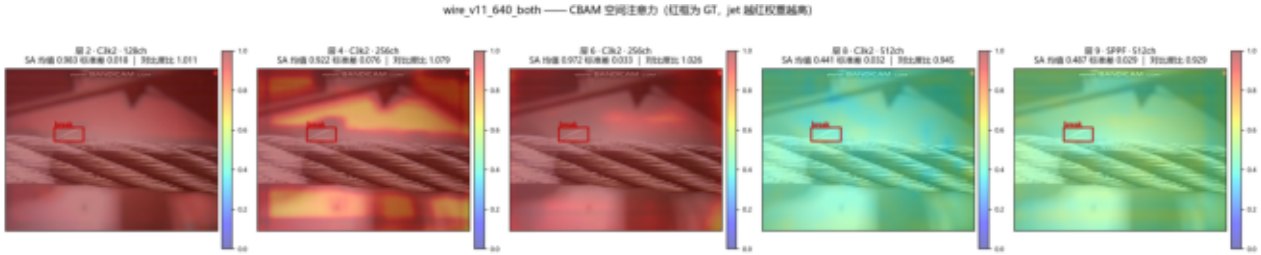


图 4　CBAM 空间注意力热力图（wire_v11_640_both；叠加在测试图上；5 层的框内/框外比均在 1.0 附近，0.957~1.110，即对缺陷无稳定偏好）

配置	320 SGD	320 AdamW	640 SGD	640 AdamW
v11 baseline	0.7787	0.7817	0.8992	0.8873
+ CBAM (backbone)	0.7360 (-0.0427)	0.7418 (-0.0399)	0.9061 (+0.0069)	0.8898 (+0.0025)
+ CBAM (neck_sppf)	0.7939 (+0.0152)	0.7908 (+0.0091)	0.9016 (+0.0024)	0.8879 (+0.0006)
+ CBAM (both)	0.7559 (-0.0228)	0.7731 (-0.0086)	0.8960 (-0.0032)	0.8998 (+0.0125)

表 10　CBAM 插入位置消融（test mAP50，括号内为相对同套 baseline 的差值；640 AdamW 一套未跑 v12，v11 四组齐全，不影响本表）

四种设置下 CBAM 都没有表现出稳定增益，差值方向随优化器与分辨率改变：

- 320 + SGD：仅 neck_sppf 为正（0.7939，+0.0152），backbone −0.0427、both −0.0228。
- 320 + AdamW：仅 neck_sppf 为正（0.7908，+0.0091），backbone −0.0399、both −0.0086。
- 640 + SGD：三处全部落在 ±0.007 以内（+0.0069 / +0.0024 / −0.0032），可视为无差异。
- 640 + AdamW：both 为正（0.8998，+0.0125），backbone +0.0025、neck_sppf +0.0006；而同一配置在 640 + SGD 下 both 是负值，方向相反。

此外，YOLOv12s 上 CBAM 的方向也不稳定：320 SGD 下由 0.7611 降至 0.7435（−0.0176）、320 AdamW 下由 0.7785 升至 0.7824（+0.0039）、640 SGD 下由 0.8682 升至 0.8874（+0.0192）。综合看，CBAM 的增益幅度随分辨率提高而被稀释（320 下最大 ±0.04，640 下最大 ±0.013），方向随优化器、分辨率与架构变化，不宜作为通用涨点手段。原因推测为：本任务目标尺度小、训练样本有限（仅 1428 张），骨干浅层的空间注意力容易放大背景导线纹理的响应，干扰细长线状目标的特征表达；而 640 输入下目标有效像素已充足，注意力机制可补充的信息本就不多。

六、各类别结果

表 11 给出四套全部模型在三个类别上的 test mAP50（按套与优化器分组）。

尺寸	优化器	模型配置	break 断股	thunderbolt 雷击	wear 磨损	整体 mAP50
320	SGD	v11+CBAM(neck_sppf)	0.558	0.964	0.860	0.7939
320	SGD	v11 (baseline)	0.560	0.954	0.822	0.7787
320	SGD	v12 (baseline)	0.524	0.943	0.816	0.7611
320	SGD	v11+CBAM(both)	0.522	0.973	0.773	0.7559
320	SGD	v12+CBAM	0.482	0.935	0.814	0.7435
320	SGD	v11+CBAM(backbone)	0.552	0.948	0.707	0.7360
320	SGD	v5 (YOLOv5s)	0.556	0.937	0.671	0.721
320	AdamW	v11+CBAM(neck_sppf)	0.596	0.973	0.803	0.7908
320	AdamW	v12+CBAM	0.558	0.941	0.848	0.7824
320	AdamW	v11 (baseline)	0.577	0.938	0.830	0.7817
320	AdamW	v12 (baseline)	0.525	0.950	0.860	0.7785
320	AdamW	v11+CBAM(both)	0.575	0.949	0.796	0.7731
320	AdamW	v5 (YOLOv5s)	0.533	0.963	0.769	0.755
320	AdamW	v11+CBAM(backbone)	0.562	0.951	0.712	0.7418
640	SGD	v5 (YOLOv5s)	0.831	0.969	0.921	0.907
640	SGD	v11+CBAM(backbone)	0.853	0.969	0.896	0.9061
640	SGD	v11+CBAM(neck_sppf)	0.827	0.973	0.904	0.9016
640	SGD	v11 (baseline)	0.811	0.969	0.918	0.8992
640	SGD	v11+CBAM(both)	0.801	0.977	0.910	0.8960
640	SGD	v12+CBAM	0.796	0.970	0.896	0.8874
640	SGD	v12 (baseline)	0.754	0.961	0.890	0.8682
640	AdamW	v11+CBAM(both)	0.835	0.966	0.899	0.8998
640	AdamW	v5 (YOLOv5s)	0.787	0.972	0.913	0.891
640	AdamW	v11+CBAM(backbone)	0.809	0.968	0.892	0.8898
640	AdamW	v11+CBAM(neck_sppf)	0.834	0.941	0.889	0.8879
640	AdamW	v11 (baseline)	0.791	0.968	0.903	0.8873

表 11　四套测试集的分类别 mAP50（每套内按整体 mAP50 降序；640 AdamW 5 行，缺 v12 两组）

三类缺陷中，雷击（thunderbolt）检测效果最好，全部 26 行都在 0.935 以上——其局部熔痕特征对比度高、与背景区分度大；磨损（wear）次之，320 下 0.671~0.860、640 下 0.889~0.921，随分辨率明显改善且更集中。

最值得说明的是断股（break）：在 320 下它是唯一的性能瓶颈，14 行模型的 break mAP50 落在 0.482~0.596，其中 9 行低于 0.56，与同期雷击相差约 0.36~0.45；在 640 下各组升至 0.754~0.853，与雷击的差距收窄到约 0.11~0.21，且不再有个别组塌陷到 0.5 以下。断股是细长线状目标、像素占比低，断口处的单丝结构与正常导线纹理高度相似，320 输入下有效像素被进一步压缩；提高分辨率后其可用信息显著增加，瓶颈随之解除。即此前「断股是类别级瓶颈」的判断只在 320 下成立。

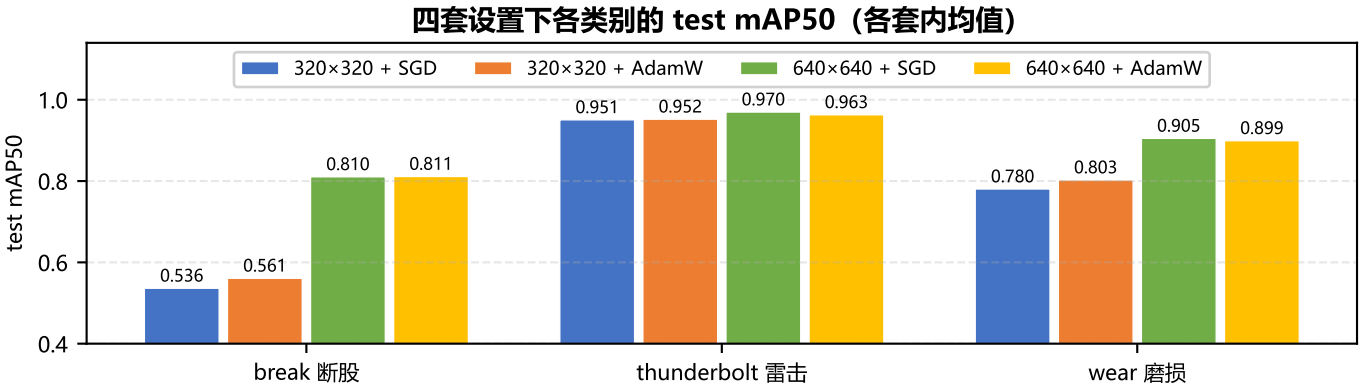


图 5　各类别 test mAP50 对比（横轴为类别，四色为四套，各套内取均值）

七、训练曲线

图 6、图 7 分别为 YOLOv11s 基线在 320×320（wire_v11_v3）与 640×640（wire_v11_640）下的 60 epoch 训练曲线，包含训练损失与验证集 mAP。两组仅输入尺寸不同，其余配置完全一致，可直接对比。

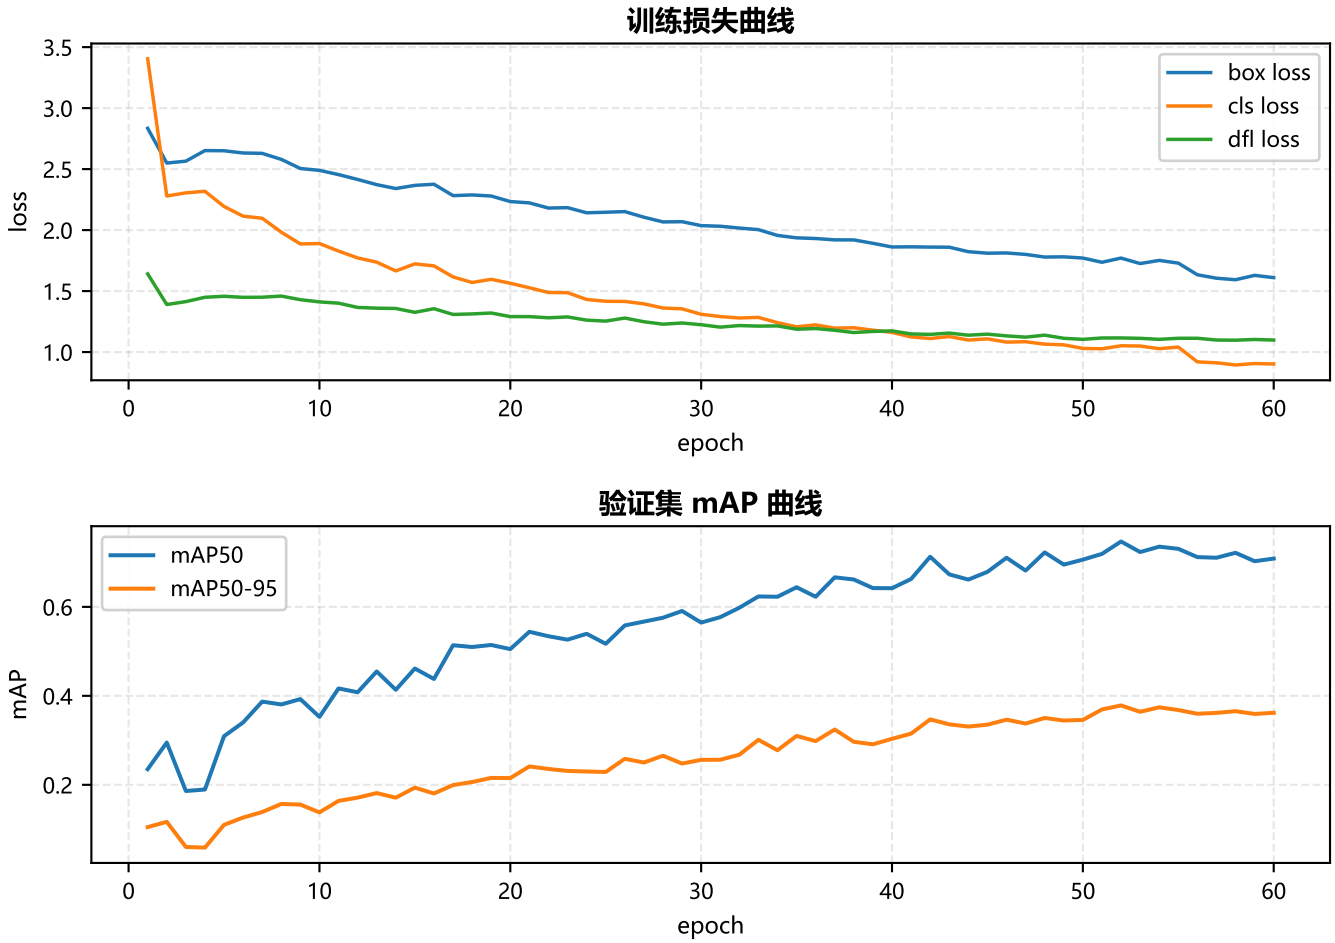


图 6　YOLOv11s 基线训练曲线 @ 320×320（数据源：runs/wire_v11_v3）

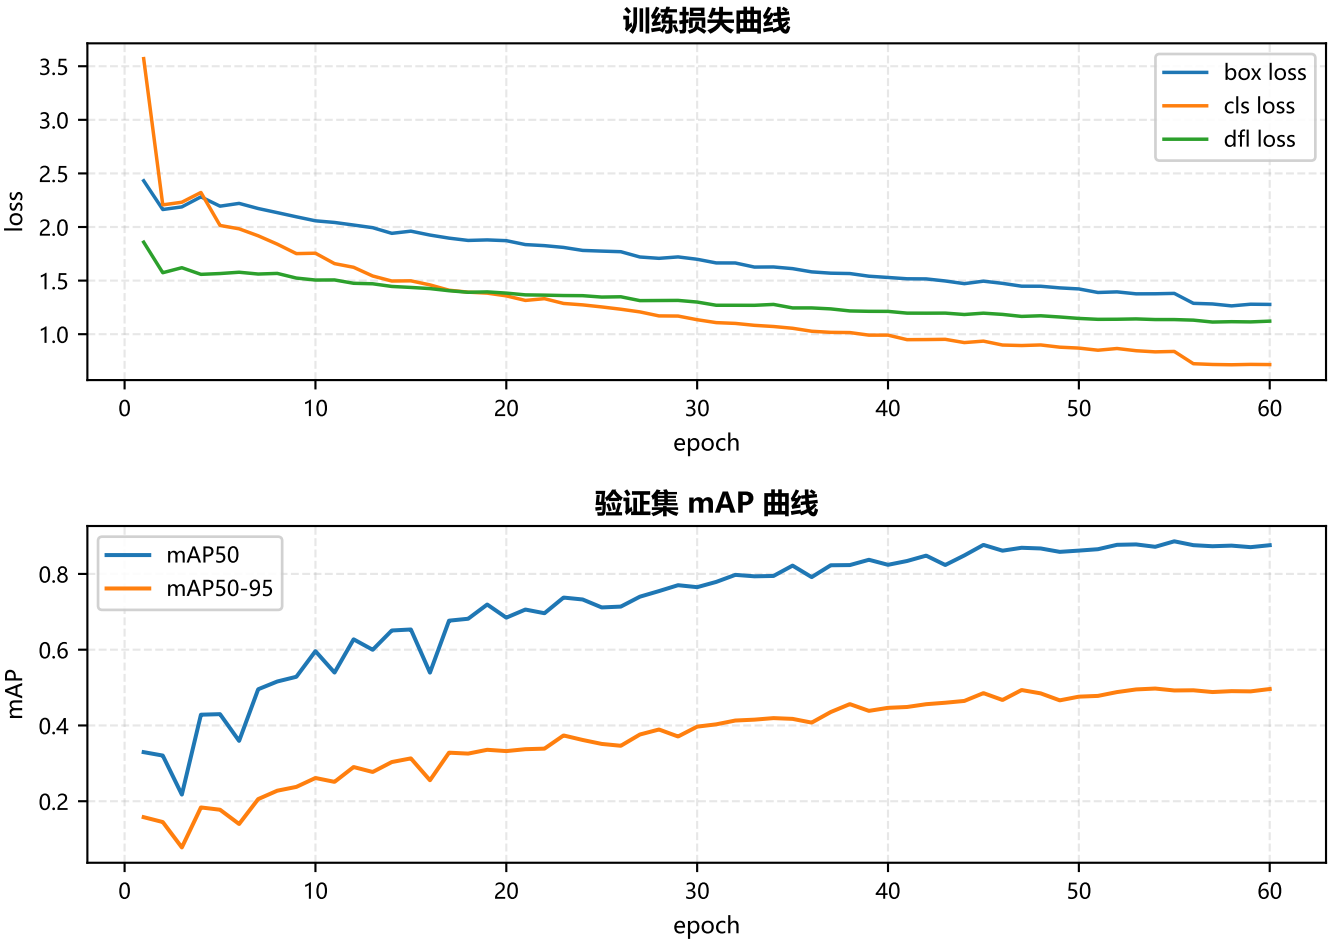


图 7　YOLOv11s 基线训练曲线 @ 640×640（数据源：runs/wire_v11_640）

两条曲线均未见明显过拟合：60 epoch 内验证集 mAP 仍在缓慢上升、训练损失仍在下降，说明训练轮数尚未饱和，延长训练仍有空间（见第九章）。

数据完整性说明：wire_v11_640_neck 与 wire_v11_640_backbone 各训练了两段，neck/backbone 第一段因 WinError 1455 页面文件不足中断，取最后一段（本报告的「60 轮」叙事与 best/last 权重均取自最后一段）。

八、问题与原因

- 问题一：YOLOv5s 的 mAP50 最高（640 下 0.907），YOLOv11s 未反超。原因：（a）YOLOv5 使用 anchor 机制，对细长线状目标（断股）的先验框匹配更友好，这正是本任务最难的类别；（b）YOLOv5s 在 60 epoch 内仍在涨（损失曲线未收敛），而 v11 在高分辨率下收敛更快，即 v5 这一侧尚未跑满，两者不处在同一训练充分度上。
- 问题二：CBAM 未带来稳定增益。增益方向对优化器与插入位置敏感（640 下四套设置的差值全部落在 ±0.013 以内且方向不一致），说明其效果接近噪声量级，而非稳定的结构改进。

对问题二做了专门的机理排查（code/tools/viz_cbam_attention.py 与 code/tools/analyze_cbam_degradation.py），结论是：CBAM 在本任务里近似恒等映射，而根因既不是任务难度，也不是注意力模块选型，而是空间注意力读出头（7×7 卷积 + sigmoid）的结构性缺陷。

- 现象层：6 个 CBAM 模型 × 21 个 CBAM 模块 × 8 张测试图的跨图聚合（口径为「同一模块在 8 张图上的波动范围」，并非 168 个独立样本）显示 —— 空间注意力标准差中位数 0.0308（最大 0.0960）、通道注意力标准差中位数 0.0259、对比度比（框内均值/框外均值）中位数 1.0152。即空间注意力接近常数场、通道门控接近均匀分布，两者相乘相当于给特征图乘一个常

数。

- 排除「梯度传不到」：在一轮真实训练的每个反向传播上挂 backward hook，实测 CBAM 权重梯度范数为宿主层的 6.23e-02（最小 1.44e-02），远高于「梯度消失」的 1e-3 判据；且 1 个 epoch 的权重位移速率与宿主层同量级（比值 0.981）。
- 排除「权重根本没动」：CA 权重每 epoch 相对位移 0.957%，宿主层 0.975%。需说明的是，静态检查里「权重 std 停在初始化附近」不能推出「没学到」——各向同性的随机游走本就近似保住权重范数，只有方向一致的漂移才会显著改变它；该证据只说明位移没有方向。
- 定位到读出头：空间注意力的输入（通道均值图与通道最大值图的拼接）本身带着缺陷的区分信息 —— 通道最大值图的空间标准差 0.26~0.71（全部 > 0.05，且高于同尺寸随机噪声图的对照 0.27~0.52），框内/框外比 1.19~1.94；而经过 7×7 卷积 + sigmoid 之后，输出的框内/框外比只剩 0.98~1.09。即读出头把 1.4~1.9 倍的区分度压回了 ~1。
- 两种压缩机制（均由 sigmoid 造成）：（a）较浅层（层 2/4/6）卷积输出带有大的正直流分量（+3.1 ~ +4.9），sigmoid 单边饱和到 ≈1，输出是常数 1；值得注意的是噪声图的该分量反而更大（8.3 / 5.0 / 6.7），说明该直流分量与图像内容无关，是「正均值输入 × 无偏置卷积」的结构性偏置；（b）较深层（层 8/9）卷积输出 ≈ 0（−0.08 / −0.23），输出落在 sigmoid 线性区、近似常数 0.5，且卷积输出的幅度先比输入小 2~5 倍。
- 为什么这解释了「无增益」：一个近似常数的注意力图，在数学上会被紧随其后的批归一化层严格吸收（BN(c·x) = γ(cx − cμ)/√(c²σ²) + β = BN(x)，常数缩放的梯度恒为 0），网络无法从这个自由度学到任何东西。

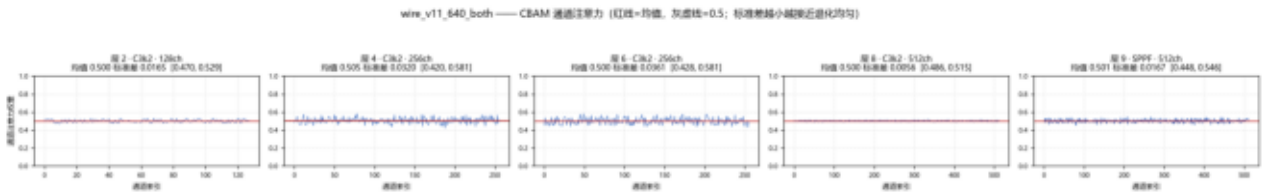


图 8　CBAM 通道注意力权重图（wire_v11_640_both；各层权重近似均匀分布，跨图标准差 0.006~0.033，无区分度）

- 遗留的原因假设已作废：此前怀疑「骨干浅层的空间注意力放大背景导线纹理响应」，但实测空间注意力的输出对缺陷的框内/框外比是 0.98~1.09（近 1），它既不放大缺陷也不放大背景，而是被 sigmoid 压成了常数 —— 该假设不成立。
- 问题三：优化器的效果不稳定（320 与 640 下方向相反）。原因：（a）两种优化器使用各自匹配的学习率（0.01 / 0.001），在不同分辨率下的有效步长与梯度噪声水平不同，AdamW 的自适应步长在小尺度、高噪声梯度下优势更明显，而尺度变大后梯度更稳定，SGD 的隐式正则反而更有利；（b）差异量级（<0.02）本就在测试集波动范围内（test 仅 179 张 / 283 框），因此不构成普适规律。
- 旁证：训练中途日志里的 Speed: 行不可用于比较推理速度（曾出现 640 组 3.6 ms < 320 组 6.9 ms 的物理上不可能的结果），本地报告的推理数据一律取自专门的端到端基准（logs/fps_benchmark.txt）。

九、解决方案

- 提高输入分辨率到 768：本任务原图为 1294×654，640 下仍有下采样空间；实测 320→640 提升 +0.14，768 有望继续受益（需评估显存与实时性）。
- 增加训练轮数到 150：v5 与 v11 的曲线在 60 epoch 时均未收敛，延长训练有望同时提升两者，

也可能改变 v5 与 v11 的相对次序。

- 离线数据增强：断股实例仅 1295 个且形态单一，用离线增强（旋转/拼接/局部裁剪+Copy-Paste）扩充细长目标样本，针对性强化最弱类别。
- 两阶段检测：先检出导线区域，再在局部高分辨率 ROI 上做缺陷分类/检测，用等效放大换取断口的有效像素，同时控制整体推理成本。

以下为待验证方向，尚未做实验，不作为本报告的解决方案：

- 待验证方向一：修改空间注意力的读出头，而非更换注意力模块。第八章的实测表明瓶颈是「7×7 卷积 + sigmoid」这一读出头把输入的区分度压成了常数，因此可试的方向是中心化空间注意力的输入（先减去空间均值再卷积，以消除造成饱和的直流分量）、或换用非饱和激活。该方向需实验验证后才可下结论。
- 待验证方向二（原「换 SE/ECA」）：SE / ECA 只做通道注意力、参数更少，在小目标少样本任务上通常更稳 —— 但本任务不适用这一通常经验：SE/ECA 同样依赖全局池化 + MLP，若本任务的根本原因是梯度无法驱动注意力分支，换模块未必能解决。需先验证梯度问题，再决定是否换模块。（实测已排除「梯度传不到」，瓶颈在空间注意力的读出头；SE/ECA 是纯通道模块，不走这条路，也等于没有回答第八章暴露的问题。）
- TensorRT INT8 量化：面向 Jetson Orin Nano 部署，在 640 输入（6.48 ms/张 @RTX 4060）基础上做 FP16/INT8 量化与层融合，换取边缘端实时性。

十、结论与局限

10.1 推荐模型综合对比

下表在统一口径下对比两个候选模型。指标（mAP50 / mAP50-95 / P / R）取自 896×896——v11 与 v5 唯一共同跑过的高分辨率尺寸；FPS 取自 640×640 端到端基准（896 未做推理基准）。

维度	v11	v5	说明
mAP50	0.9148	0.9310	v5 高 1.6pt（方向性，非量化）
mAP50-95	0.5362	0.5290	v11 高 0.7pt
FPS	154	98	v11 快 57%
架构	2024	2020	
P	0.940	0.902	
R	0.821	0.877	

表 12　推荐模型综合对比（v11 = YOLOv11s 基线，v5 = YOLOv5s；mAP50/mAP50-95/P/R 取自 896×896，FPS 取自 640×640 端到端基准）

综合 mAP50-95、推理速度、精确率与架构代际，v11 为本数据集推荐模型；v5 在 mAP50 与召回率上略优，两者差异只作方向性表述。

结论：

- 分辨率是压倒性主变量：320 → 640 使 test mAP50 均值提升约 +0.14（0.7557/0.7719 → 0.8951/0.8912），mAP50-95 提升约 +0.13，且几乎覆盖全部模型配置。断股类从 0.48~0.60 提升到 0.75~0.85，此前的类别级瓶颈被解除。
- 优化器影响次之且方向不稳定：320 下 AdamW 略高（7 组均值 +0.0162），640 下 SGD 略高（同构子集 −0.0095 ~ −0.0108），方向反转。真正决定性的是学习率与优化器是否匹配（错配 lr0=0.01 时 mAP50 仅 0.635，纠正后 0.779）。

- CBAM 无稳定增益：四种设置（320/640 × SGD/AdamW）下差值方向不一致，640 下全部落在 ±0.013 以内，不能作为通用涨点手段。
- 推荐模型：YOLOv11s 基线。按 mAP50，YOLOv5s（0.907）略高于 v11（0.8992）（差 0.8pt，在组内极差 1.01pt 内）；但按 mAP50-95（定位精度）v11（0.5286）高于 v5（0.500），推理速度快约 57%（154 vs 98 FPS），且架构代际更新。综合这三项，本数据集推荐 YOLOv11s，依据见上方表 12。

局限：

- 验证集（178 张 / 275 实例）与测试集（179 张 / 283 实例）规模都偏小，单次评估置信区间较宽，组间小于 0.01 的差异（如 CBAM 在 640 下的增益、优化器在同构子集下的差值）不宜作强结论。
- 640 + AdamW 一套只有 5 组（缺 v12 两组），四套并非完全对称，凡是跨 640 两套的均值比较都必须按同构子集做，本报告已如此处理。
- 未做分辨率的连续扫描（如 480、512、768）与训练时长扫描，640 是否接近任务上限、60 epoch 是否训练充分均未确定。
- 推理基准只测了 8 组（架构 × 尺寸），两个 CBAM 组与 v12+CBAM 未单测，表中以「—」标注；且本机为笔记本 GPU，SM 频率存在热漂移，锁频需管理员权限，故采用顶频 + 轮转 + 丢首轮的方式控制，组间小于 0.2 ms 的差异不应解读。
- 各框架仍保留各自推荐的其余超参（数据增广强度、损失权重、warmup 策略等），仅对齐了优化器、初始学习率、输入尺寸与随机种子；论文中应注明「各框架采用各自推荐配置，通用超参保持一致」。

十一、896×896 对照（独立口径，不与 640 混算）

本条与前面的四套分开陈述，原因有二：（1）896 只跑了 YOLOv11s 基线与 YOLOv5s 两个配置（无 CBAM 组、无 v12），样本不足以构成完整的一套；（2）896 与 640 输入尺寸不同，若并入 640 的均值会把「尺寸差」混进「模型差」。故 896 的读数只作同尺寸内的两两对照，不与 640 的数值相加或求均值。

两组的训练超参已对齐：同为 SGD + lr0=0.01、batch=8、imgsz=896、60 epoch、seed=42；唯一未对齐的是末端学习率比例（v5 一侧 lrf=0.01，v11 一侧 lrf=0.005）。

注（v5-vs-v11 的口径，同第二章 lrf 注）：v5 与 v11 的 lrf 不同（v5 lrf=0.01、cos_lr=false，线性衰减；v11 lrf=0.005、cos_lr=true，余弦衰减），该不对称在 320 / 640 / 896 各套中逐字相同，在本实验范围内不影响分辨率相关结论；但 v5-vs-v11 的量化比较须注明此不对称。

模型配置	P	R	mAP50	mAP50-95	break 断股	thunderbolt 雷击	wear 磨损	参数量
v5 (YOLOv5s)	.902	.877	.931	.529	.862	.973	.957	7,027,720
v11 (baseline)	.9401	.8212	.9148	.5362	.870	.962	.912	9,428,953

表 13　896×896 下的 test 结果（best.pt；数据源 logs/eval_896.log；v5 按源精度 3 位；896 未做推理基准，表中不含 ms/FPS）。参数量口径：v11 训练参数量 9,428,953（logs/train_896.log），fused 后 9,413,961（BN 折叠，logs/eval_896.log），全表统一用训练参数量。

896 下的模型间方向与 640 同向：YOLOv5s 的 mAP50（0.931）高于 YOLOv11s（0.9148），与 640 下 v5 在 mAP50 上领先一致，说明「v5 的 mAP50 更高」不是 640 单点的偶然。但从 mAP50-95 看，v11（0.5362）略高于 v5（0.529），也与 640 下 v11 的定位优势一致。

断股（break）在 896 下仍是三类中最弱（v11 0.870 / v5 0.862），且其 mAP50-95 只有 0.449 / 0.426，远低于同尺寸雷击（0.620 / 0.603）：即 896 已能修正细长目标的「大致定位」（mAP50），

却仍未改善其「精细定位」。

公平性边界：两组同为 SGD / lr0=0.01 / batch=8 / 60 epoch / seed=42，差异集中在框架自身的实现（anchor 机制、损失与增广默认值）与 lrf（0.01 vs 0.005）。故本对照足以支撑「同尺寸下 v5 的 mAP50 更高」这一方向性结论。量化边界：896 只有一个尺寸、每组仅一个模型，本身没有组内重复，无法直接估计噪声尺度；故借用 640 同架构四组的组内极差 1.01pt 作代理，本组 1.6pt 略超该代理 → 其差值不作量化比较，只作方向性结论。

十二、数据泄漏与 clean 子集核查（报告口径）

方法：dHash 汉明距离 ≤2 划 leak、其余 clean；5 个随机划分种子做置换检验。

本数据集由视频分帧得到，训练/测试之间可能存在同场景近复制品。若存在，报告中的 test 指标会被「记忆」抬高。为此做了一次专门的泄漏核查：用 dHash 汉明距离把 test（与 val）划成 leak（最近邻距离 ≤2，近复制品）与 clean（无近复制品）两个子集，分别评估，并以 5 个随机划分种子做置换检验。

核查结论（报告口径原文，不得改写）：

test 侧泄漏效应不可分辨（两格 p=0.60）；机理是样本量最小类的 AP 在小子集上不可稳定估计——四格无一格三类同号，每格由单一类主导（56%~171%），其中 wear 跨格符号一致。跨格符号一致只说明「每次都是同一个薄类被小样本反复主导」，不含可识别机制。val 侧两格超出零分布，但同样由 wear 主导（896 独扛 110%、640 占 56.3%），且 val_leak 的 wear 仅 3 图/16 实例 → 该超出不可解读为泄漏效应。结论：报告口径不修正 headline；clean 子集读数备查；clean ≠ 未见过的场景。

模型 / split	总分差(点)	break	thunderbolt	wear	主导类（占比）
896 test	+0.91	+1.15	+2.89	−1.30	tb（+106%）
640 test	+1.81	+9.30	−2.50	−1.30	break（+171%）
896 val	+4.49	−0.38	−0.94	+14.83	wear（+110%）
640 val	+9.29	+9.57	+2.62	+15.70	wear（+56%）

表 14　leak − clean 的逐类拆解（单位：点；每类对 mAP50(all) 的贡献 = 该类 AP 差 ÷ 3）。四个格子里没有一格三类同号，且每格都由单一类主导（|占比| 56%~171%）

由表 14 可见：leak−clean 的总分差由单一类别主导；wear 一类的符号在 val 两格一致为正（+15.70/+14.83）、在 test 两格一致为负（−1.30/−1.30）。这不是随机的正负抵消，而是「样本量最小的那一类（val_leak 中 wear 仅 3 图/16 实例）在小子集上的 AP 波动」主导了差值——即这些差值不可读作泄漏的度量。

部署与写作含义：报告中的 test 指标不因泄漏而需要修正；但「clean 子集」只表示「无近复制品」，不等于「未见过的场景」（clean 中仍有大量疑似同段视频的别帧），因此不得据此宣称模型可泛化到新场景。该限制不改变第十章的数据集内模型选择结论——推荐基于同一数据集内的相对性能，不含跨场景泛化背书。另需注意：val 的 best.pt 由完整 val 选出，val 侧还混入选择效应，故 val 侧的 leak−clean 双重不干净，只作备查。